

# Intervalos de Confianza y Predicción

## Modelado Probabilístico para Curvas de Performance de Pozos ( $Q_o$ vs $Q_{gl}$ )

### 1. Resumen

En este documento se aborda la construcción formal de intervalos de confianza y de predicción para estimar la tasa de producción de aceite ( $Q_o$ ) según la inyección de gas ( $Q_{gl}$ ), considerando un conjunto de  $n$  datos de pruebas de pozo ( $Q_{gl}, Q_o$ ). A partir de una reestructuración de la ecuación empírica propuesta por Hamed Namdar <https://doi.org/10.1007/s13202-019-0697-7> para curvas de performance de gas lift, el modelo es lineal en sus parámetros, lo que permite aplicar el formalismo matricial exacto de regresión lineal múltiple.

### 2. Contextualización y Planteamiento del Problema

Como parte del proceso de optimización de asignación de gas lift, se requiere ajustar las curvas de performance a  $n$  muestras tomadas. Debido a la variabilidad inherente a los datos de campo, la relación determinística de Hamed Namdar en el plano ( $Q_{gl}, Q_o$ ):

$$Q_o = a + b \cdot Q_{gl} + c \cdot Q_{gl}^{0.7} + d \cdot \ln(Q_{gl} + 0.9) + e \cdot \exp(-Q_{gl}^{0.6}) \quad (1)$$

resulta insuficiente para describir la aleatoriedad intrínseca del proceso muestral. Para ello se desean introducir intervalos de confianza para estimar con un nivel de significancia habitual de  $\alpha = 0.05$  la media de la producción  $Q_o$  para un determinado  $Q_{gl}$  es decir,  $\mu = \mathbb{E}[Q_o | Q_{gl}]$  y por tanto<sup>1</sup>,

$$IC_{(1-\alpha)}(\mu) = \hat{\mu}(Q_{gl}) \pm \delta(Q_{gl}). \quad (2)$$

Para simplificar la notación, usaremos  $\mu = \mathbb{E}[Q_o | Q_{gl}] = \mathbb{E}[Q_o]$  teniendo en cuenta que el valor esperado se toma para la variable aleatoria  $Q_o$  y un valor fijo de  $Q_{gl}$ . Para encontrar las formas funcionales de  $\hat{\mu}(Q_{gl})$  y  $\delta(Q_{gl})$  se recurre a una versión estocástica de la ecuación (1):

$$Q_o = a + b \cdot Q_{gl} + c \cdot Q_{gl}^{0.7} + d \cdot \ln(Q_{gl} + 0.9) + e \cdot \exp(-Q_{gl}^{0.6}) + \epsilon \quad (3)$$

donde  $a, b, c, d, e$  son coeficientes constantes de correlación a estimar. Este modelo probabilístico tiene la forma  $Y = f(\mathbf{x}) + \epsilon$ , donde  $\epsilon \sim \mathcal{N}(0, \sigma^2)$  representa el componente estocástico de error y  $\mathbf{x} \in \mathbb{R}^p$  es una cantidad determinista dependiente de la elección de  $Q_{gl}$  donde  $p$  es la cantidad de términos del modelo de modo que  $p = 5$  para el modelo de Namdar (1).

### 3. Estructura del Modelo: Linealidad en los Parámetros

Aunque la ecuación (3) involucra funciones no lineales de  $Q_{gl}$  ( $\ln$ ,  $\exp$ , potencias, etc.), los coeficientes desconocidos entran de forma estrictamente lineal. Por otro lado, defina el camino  $\mathbf{x} : \mathbb{R} \rightarrow \mathbb{R}^5$  definido por:

$$Q_{gl} \mapsto \mathbf{x}(Q_{gl}) = \begin{bmatrix} 1 \\ Q_{gl} \\ Q_{gl}^{0.7} \\ \ln(Q_{gl} + 0.9) \\ \exp(-Q_{gl}^{0.6}) \end{bmatrix} \quad (4)$$

Defina también:

$$\beta = \begin{bmatrix} a \\ b \\ c \\ d \\ e \end{bmatrix}. \quad (5)$$

<sup>1</sup>Note que en esta expresión  $Q_{gl}$  es constante pero variable,  $\mu$  es constante pero variable y  $Q_o$  es una variable aleatoria sobre la cual se está integrando para calcular el valor esperado o media.

Defina la función  $f : \mathbb{R}^5 \rightarrow \mathbb{R}$  dada por  $f(\mathbf{x}) = \mathbf{x}'\boldsymbol{\beta}$ . El modelo estocástico para estimar la curva de performance toma la forma de una regresión lineal múltiple:

$$\begin{aligned} Q_o &= f(\mathbf{x}) + \epsilon \\ &= \mathbf{x}'\boldsymbol{\beta} + \epsilon \\ &= a + bx_1 + cx_2 + dx_3 + ex_4 + \epsilon \end{aligned} \quad (6)$$

*Aclaración:* los parámetros  $a, b, c, d, e$  son parámetros poblacionales del pozo a estimar fijos pero desconocidos. Las variables independientes  $x_1, x_2, x_3, x_4$  se tratan como determinísticas (son valores fijos dados por las condiciones operativas de inyección de gas  $Q_g$ ). Finalmente,  $\epsilon$  es una variable aleatoria, y representa la única fuente de incertidumbre o ruido estocástico en la medición. Por tanto,  $Q_o$  es una variable aleatoria únicamente porque es una función lineal de la variable aleatoria de error  $\epsilon$ . Calculemos explícitamente  $\mu$ :

$$\begin{aligned} \mu &= \mathbb{E}[Q_o \mid Q_{gl}] \\ &= \mathbb{E}[\mathbf{x}'\boldsymbol{\beta} + \epsilon \mid Q_{gl}] \\ &= \mathbb{E}[\mathbf{x}'\boldsymbol{\beta} \mid Q_{gl}] + \mathbb{E}[\epsilon \mid Q_{gl}] \\ &= \mathbf{x}'\boldsymbol{\beta} \end{aligned} \quad (7)$$

Por lo tanto  $\mu = \mu(\mathbf{x}) = \mathbf{x}'\boldsymbol{\beta}$ . Por otro lado, si  $\hat{\boldsymbol{\beta}}$  es un vector de estimadores de  $\boldsymbol{\beta}$  dado por,

$$\hat{\boldsymbol{\beta}} = \begin{bmatrix} \hat{a} \\ \hat{b} \\ \hat{c} \\ \hat{d} \\ \hat{e} \end{bmatrix}, \quad (8)$$

entonces un estimador para  $\mu$  será dado por  $\hat{\mu} = \mathbf{x}'\hat{\boldsymbol{\beta}}$ . En la siguiente sección se muestra cómo calcular los estimadores del vector en (8).

#### 4. Formulación Matricial para Estimar Coeficientes y Media

Para una muestra de tamaño  $n$  de la forma:

$$(Q_{gl}^{(1)}, Q_o^{(1)}), (Q_{gl}^{(2)}, Q_o^{(2)}), (Q_{gl}^{(3)}, Q_o^{(3)}), \dots, (Q_{gl}^{(n)}, Q_o^{(n)})$$

se define la matriz de dimensión  $n \times 5$ , dada por:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} & x_{14} \\ 1 & x_{21} & x_{22} & x_{23} & x_{24} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{bmatrix} = \begin{bmatrix} 1 & Q_{gl}^{(1)} & (Q_{gl}^{(1)})^{0.7} & \ln(Q_{gl}^{(1)} + 0.9) & \exp\left(- (Q_{gl}^{(1)})^{0.6}\right) \\ 1 & Q_{gl}^{(2)} & (Q_{gl}^{(2)})^{0.7} & \ln(Q_{gl}^{(2)} + 0.9) & \exp\left(- (Q_{gl}^{(2)})^{0.6}\right) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & Q_{gl}^{(n)} & (Q_{gl}^{(n)})^{0.7} & \ln(Q_{gl}^{(n)} + 0.9) & \exp\left(- (Q_{gl}^{(n)})^{0.6}\right) \end{bmatrix}$$

Defina el vector de producciones de las muestras como:

$$\mathbf{Q}_o = \begin{bmatrix} Q_o^{(1)} \\ Q_o^{(2)} \\ \vdots \\ Q_o^{(n)} \end{bmatrix} \quad (9)$$

Usando OLS (*Ordinary Least Squares*) obtenemos los estimadores de la regresión lineal múltiple como:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q}_o \quad (10)$$

El vector  $\hat{\beta}$  contiene las *estimaciones* puntuales de los parámetros poblacionales  $\beta$  i.e. los valores sobre la recta de regresión que minimizan la suma de las diferencias al cuadrado en OLS, de modo que para la muestra  $(Q_{gl}^{(j)}, Q_o^{(j)})$  con  $j \in \{1, 2, ts, n\}$ :

$$\hat{\mu}_j = \mathbf{x}'_j \hat{\beta}. \quad (11)$$

En términos de la matriz  $\mathbf{X}$  y de la matriz de medias estimadas  $\hat{\boldsymbol{\mu}}' = [\hat{\mu}_1 \quad \hat{\mu}_2 \quad \cdots \quad \hat{\mu}_n]$  se tiene:

$$\hat{\boldsymbol{\mu}} = \mathbf{X} \hat{\beta}. \quad (12)$$

Análogamente a partir de la ecuación (7), las medias poblacionales  $\boldsymbol{\mu}' = [\mu_1 \quad \mu_2 \quad \cdots \quad \mu_n]$  se pueden condensar en el siguiente producto,

$$\boldsymbol{\mu} = \mathbf{X} \beta. \quad (13)$$

*Aclaración:* Estimaciones y estimadores son conceptos diferente. un estimador es una variable aleatoria y una estimación es la realización al hacer el proceso de muestreo. Por el contexto se entiende si  $\hat{\beta}$  se refiere al estimador o a la estimación.

Defina la función  $\mathbf{f} : M_{n \times 5}(\mathbb{R}) \rightarrow \mathbb{R}^n$  tal que  $\mathbf{f}(\mathbf{X}) = \mathbf{X} \beta$ . Defina también el vector aleatorio:

$$\boldsymbol{\epsilon} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix} \quad (14)$$

bajo los supuestos de *Gauss-Markov* [1], es decir

$$\mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0} \quad \text{y} \quad \text{Var}(\boldsymbol{\epsilon}) = \mathbb{E}[\boldsymbol{\epsilon} \boldsymbol{\epsilon}'] = \sigma^2 \mathbf{I}_n \quad (15)$$

Esto significa que los errores están centrados en cero, que ninguna observación aporta más variabilidad o ruido residual que otra (homocedasticidad) y que el residuo de una prueba/muestra no influye ni da información sobre el residuo de otra (no autocorrelación). Con estas hipótesis más la hipótesis de normalidad  $\epsilon_j \sim \mathcal{N}(0, \sigma^2)$  para cada  $j \in \{1, 2, \dots, n\}$  se deduce que  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ .

Desde el punto de vista de estimador, observe que  $\hat{\beta}$  de la ecuación (10) es un vector aleatorio porque es función de  $\mathbf{Q}_o$  visto como el vector aleatorio  $\mathbf{Q}_o = \mathbf{f}(\mathbf{X}) + \boldsymbol{\epsilon}$  i.e.,

$$\mathbf{Q}_o = \mathbf{f}(\mathbf{X}) + \boldsymbol{\epsilon} = \mathbf{X} \beta + \boldsymbol{\epsilon} = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} & x_{14} \\ 1 & x_{21} & x_{22} & x_{23} & x_{24} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{bmatrix} \begin{bmatrix} a \\ b \\ c \\ d \\ e \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix} = \begin{bmatrix} a + bx_{11} + cx_{12} + dx_{13} + ex_{14} + \epsilon_1 \\ a + bx_{21} + cx_{22} + dx_{23} + ex_{24} + \epsilon_2 \\ \vdots \\ a + bx_{n1} + cx_{n2} + dx_{n3} + ex_{n4} + \epsilon_n \end{bmatrix}$$

Por tanto,

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' (\mathbf{f}(\mathbf{X}) + \boldsymbol{\epsilon}) \\ &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' (\mathbf{X} \beta + \boldsymbol{\epsilon}) \\ &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{X} \beta + (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\epsilon} \\ &= \beta + (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\epsilon} \end{aligned} \quad (16)$$

La ecuación (10) es la estimación de los parámetros y la ecuación (16) es el estimador. Podemos calcular el valor esperado y la varianza del vector de estimadores  $\hat{\beta}$ . Para simplificar la notación en el cálculo del valor esperado y de la varianza de  $\hat{\beta}$  considere  $\mathbb{E}[\cdot | \mathbf{X}] = \mathbb{E}[\cdot]$ :

$$\begin{aligned} \mathbb{E}[\hat{\beta}] &= \mathbb{E}[\beta + (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\epsilon}] \\ &= \mathbb{E}[\beta] + \mathbb{E}[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\epsilon}] \\ &= \beta + (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbb{E}[\boldsymbol{\epsilon}] \\ &= \beta \end{aligned} \quad (17)$$

Calculemos la varianza,

$$\begin{aligned}
\text{Var}(\hat{\beta}) &= \mathbb{E} [(\hat{\beta} - \mathbb{E}[\hat{\beta}])(\hat{\beta} - \mathbb{E}[\hat{\beta}])'] \\
&= \mathbb{E} [(\hat{\beta} - \beta)(\hat{\beta} - \beta)'] \\
&= \mathbb{E} [((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)'] \\
&= \mathbb{E} [((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)\epsilon'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}] \\
&= \mathbb{E} [(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\epsilon\epsilon')\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\epsilon\epsilon']\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\sigma^2\mathbf{I}_n)\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}
\end{aligned} \tag{18}$$

La varianza  $\sigma^2$  representa el nivel global de ruido en las mediciones del pozo. A mayor ruido instrumental o ambiental, mayor será la variabilidad de nuestros estimadores. La matriz  $(\mathbf{X}'\mathbf{X})^{-1}$  refleja la geometría de la muestra tomada. Cuanto más dispersos y variados sean los puntos de prueba registrados en campo (mayor información en la matriz  $\mathbf{X}$ ), más pequeño será  $(\mathbf{X}'\mathbf{X})^{-1}$  y, por ende, más precisas (menor varianza) serán las estimaciones de los parámetros  $\hat{\beta}$ . Como cualquier transformación afin (lineal más una constante) de un vector normal multivariado es también un vector normal multivariado y como  $\hat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon$  con  $\epsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2\mathbf{I}_n)$  entonces  $\hat{\beta} \sim \mathcal{N}_5(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$ .

Una vez conocido un estimador para  $\hat{\beta}$  en la ecuación y su distribución, considere el camino  $\mathbf{x} : \mathbb{R} \rightarrow \mathbb{R}^5$  definido en la ecuación (4). Defina la siguiente función  $\hat{\mu} : \mathbf{x}(\mathbb{R}) \rightarrow \mathbb{R}$  tal que  $\mathbf{x} \mapsto \hat{\mu}(\mathbf{x}) = \mathbf{x}'\hat{\beta}$ . Observe que esta función en los puntos medidos de inyección coincide con las medias de las muestras de la ecuación (11).

Observe que  $\hat{\mu}$  es a su vez una variable aleatoria porque depende del vector aleatorio  $\hat{\beta}$  es decir,

$$\begin{aligned}
\hat{\mu} &= \mathbf{x}'\hat{\beta} \\
&= \mathbf{x}'(\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon) \\
&= \mathbf{x}'\beta + \mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon \\
&= \mu + \mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon
\end{aligned} \tag{19}$$

Para calcular el valor esperado del estimador  $\hat{\mu}$  podemos usar el hecho de que ya probamos que  $\hat{\beta}$  es insesgado. Calculemos el valor esperado de  $\hat{\mu}$  dado un valor de  $\mathbf{x}$ :

$$\mathbb{E}[\hat{\mu} \mid \mathbf{x}] = \mathbb{E}[\mathbf{x}'\hat{\beta} \mid \mathbf{x}] = \mathbf{x}'\mathbb{E}[\hat{\beta} \mid \mathbf{x}] = \mathbf{x}'\beta = \mu \tag{20}$$

Por lo tanto  $\hat{\mu}$  es un estimador insesgado.

Calculemos la varianza de  $\hat{\mu}$  dado un valor de  $\mathbf{x}$ , para simplificar la notación, considere  $\mathbb{E}[\cdot \mid \mathbf{x}] = \mathbb{E}[\cdot]$ ,

$$\begin{aligned}
\text{Var}(\hat{\mu} \mid \mathbf{x}) &= \mathbb{E} [(\hat{\mu} - \mathbb{E}[\hat{\mu}])(\hat{\mu} - \mathbb{E}[\hat{\mu}])'] \\
&= \mathbb{E} [(\hat{\mu} - \mu)(\hat{\mu} - \mu)'] \\
&= \mathbb{E} [(\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)(\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)'] \\
&= \mathbb{E} [(\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon)(\epsilon'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x})] \\
&= \mathbb{E} [\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\epsilon\epsilon')\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}] \\
&= \mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\epsilon\epsilon']\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x} \\
&= \mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\sigma^2\mathbf{I}_n)\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x} \\
&= \sigma^2\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x} \\
&= \sigma^2\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}
\end{aligned} \tag{21}$$

Otra forma más elegante de calcular la varianza de  $\hat{\mu}$  dado un valor de  $\mathbf{x}$  es usando la varianza ya calculada de  $\hat{\beta}$ ,

$$\begin{aligned}\text{Var}(\hat{\mu} \mid \mathbf{x}) &= \text{Var}(\mathbf{x}'\hat{\beta}) \\ &= \mathbf{x}'\text{Var}(\hat{\beta})\mathbf{x} \\ &= \mathbf{x}'(\sigma^2(\mathbf{X}'\mathbf{X})^{-1})\mathbf{x} \\ &= \sigma^2\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}\end{aligned}$$

Dado que transformación afin (lineal más una constante) de una variable aleatoria normal es también normal entonces  $\hat{\mu} = \mu + \mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}$  con  $\boldsymbol{\epsilon} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2\mathbf{I}_n)$  implica que  $\hat{\mu} \sim \mathcal{N}(\mu, \sigma^2\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}) = \mathcal{N}(\mathbf{x}'\boldsymbol{\beta}, \sigma^2\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x})$ .

## 5. Estadístico de Prueba e Intervalos de Confianza y Predicción

Estandarizemos  $\hat{\mu}$  dado un valor de  $\mathbf{x}$ :

$$Z = \frac{\hat{\mu}(\mathbf{x}) - \mathbb{E}[\hat{\mu} \mid \mathbf{x}]}{\sqrt{\text{Var}(\hat{\mu} \mid \mathbf{x})}} = \frac{\hat{\mu}(\mathbf{x}) - \mu(\mathbf{x})}{\sqrt{\text{Var}(\hat{\mu} \mid \mathbf{x})}} = \frac{\mathbf{x}'\hat{\beta} - \mathbf{x}'\boldsymbol{\beta}}{\sigma\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}}} \sim \mathcal{N}(0, 1) \quad (22)$$

No podemos usar  $Z$  directamente para construir el intervalo porque la varianza poblacional del error  $\sigma^2$  es desconocida.

### 5.1 Estimador Insesgado de la Varianza ( $s^2$ )

En el modelo de regresión estándar se asume homocedasticidad (varianza constante). Como se asume que cada residuo individual es una muestra independiente que proviene de la misma distribución normal  $\mathcal{N}(0, \sigma^2)$  entonces en lugar de estimar la varianza usando solo datos para un  $Q_g$  específico, se pueden agrupar la información de las  $n$  observaciones. Sumar todos los residuos al cuadrado nos da muchísima más precisión estadística para estimar la única varianza común  $\sigma^2$ .

$$S^2 = \frac{1}{n-p} \sum_{j=1}^n (Q_o^{(j)} - \hat{\mu}_j)^2 \quad (23)$$

donde  $Q_o^{(j)}$  es la tasa de producción observada en la  $j$ -ésima prueba,  $p = 5$  para el modelo de Namdar y  $\hat{\mu}_j = \mathbf{x}'_j\hat{\beta}$  tal que  $\mathbf{x}_j = \mathbf{x}(Q_{gl}^{(j)})$  i.e., depende de la inyección en la  $j$ -ésima prueba, más explícitamente:

$$\hat{\mu}_j = \hat{a} + \hat{b}x_{j1} + \hat{c}x_{j2} + \hat{d}x_{j3} + \hat{e}x_{j4}. \quad (24)$$

El estimador también puede expresarse en términos matriciales donde  $\mathbf{Q}_o$  se definió en la ecuación (9) y  $\hat{\boldsymbol{\mu}}$  en la ecuación (12):

$$\begin{aligned}S^2 &= \frac{1}{n-p} (\mathbf{Q}_o - \hat{\boldsymbol{\mu}})' (\mathbf{Q}_o - \hat{\boldsymbol{\mu}}) \\ &= \frac{1}{n-p} (\mathbf{Q}_o - \mathbf{X}\hat{\boldsymbol{\beta}})' (\mathbf{Q}_o - \mathbf{X}\hat{\boldsymbol{\beta}}) \\ &= \frac{1}{n-p} (\mathbf{Q}_o - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q}_o)' (\mathbf{Q}_o - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q}_o) \\ &= \frac{1}{n-p} ((\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o)' (\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o \\ &= \frac{1}{n-p} \mathbf{Q}_o' (\mathbf{I}_n - \mathbf{H})' (\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o \\ &= \frac{1}{n-p} \mathbf{Q}_o' (\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o\end{aligned} \quad (25)$$

El estimador de la varianza se divide entre  $n - p$  (donde  $p = 5$ ) para garantizar que el estimador sea insesgado, es decir, que  $\mathbb{E}[S^2] = \sigma^2$ , compensando los  $p$  grados de libertad utilizados en la estimación del vector  $\hat{\beta}$ . Probemos que en efecto  $S^2$  es un estimador insesgado.

$$\begin{aligned}
\mathbb{E}[S^2] &= \frac{1}{n-p} \mathbb{E}[\mathbf{Q}'_o(\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o] \\
&= \frac{1}{n-p} \mathbb{E}[\text{tr}(\mathbf{Q}'_o(\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o)] \\
&= \frac{1}{n-p} \mathbb{E}[\text{tr}((\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o\mathbf{Q}'_o)] \\
&= \frac{1}{n-p} \text{tr}(\mathbb{E}[(\mathbf{I}_n - \mathbf{H})\mathbf{Q}_o\mathbf{Q}'_o]) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})\mathbb{E}[\mathbf{Q}_o\mathbf{Q}'_o]) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})(\text{Var}(\mathbf{Q}_o) + \mathbb{E}[\mathbf{Q}_o]\mathbb{E}[\mathbf{Q}_o]')) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})(\text{Var}(\mathbf{X}\hat{\beta} + \epsilon) + \mathbb{E}[\mathbf{X}\hat{\beta} + \epsilon]\mathbb{E}[\mathbf{X}\hat{\beta} + \epsilon]')) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})(\text{Var}(\epsilon) + (\mathbf{X}\hat{\beta} + \mathbb{E}[\epsilon])(\mathbf{X}\hat{\beta} + \mathbb{E}[\epsilon])')) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})(\text{Var}(\epsilon) + (\mathbf{X}\hat{\beta} + \mathbb{E}[\epsilon])(\hat{\beta}'\mathbf{X}' + \mathbb{E}[\epsilon]'))) \\
&= \frac{1}{n-p} \text{tr}((\mathbf{I}_n - \mathbf{H})(\sigma^2\mathbf{I}_n + \mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}')) \\
&= \frac{1}{n-p} \text{tr}(\sigma^2(\mathbf{I}_n - \mathbf{H}) + (\mathbf{I}_n - \mathbf{H})\mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}') \\
&= \frac{1}{n-p} \text{tr}(\sigma^2(\mathbf{I}_n - \mathbf{H}) + \mathbf{X}\hat{\beta}\hat{\beta}' - \mathbf{H}\mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}') \\
&= \frac{1}{n-p} \text{tr}(\sigma^2(\mathbf{I}_n - \mathbf{H}) + \mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}' - (\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}') \\
&= \frac{1}{n-p} \text{tr}(\sigma^2(\mathbf{I}_n - \mathbf{H}) + \mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}' - \mathbf{X}\hat{\beta}\hat{\beta}'\mathbf{X}') \\
&= \frac{\sigma^2}{n-p} \text{tr}(\mathbf{I}_n - \mathbf{H}) \\
&= \frac{\sigma^2}{n-p} (\text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{H})) \\
&= \frac{\sigma^2}{n-p} (n - \text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')) \\
&= \frac{\sigma^2}{n-p} (n - \text{tr}(\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1})) \\
&= \frac{\sigma^2}{n-p} (n - p) \\
&= \sigma^2
\end{aligned} \tag{26}$$

Se puede demostrar que:

$$V = \frac{(n-p)S^2}{\sigma^2} \sim \chi^2_{n-p} \tag{27}$$

Además, bajo el supuesto de errores normales, el estimador del vector  $\hat{\beta}$  (y por ende  $Z$ ) es independiente del estimador de la varianza  $S^2$  (y por ende de  $V$ ) (?).

## 5.2 Construcción del Estadístico Pivote ( $T$ )

Por definición, si  $Z \sim \mathcal{N}(0, 1)$  y  $V \sim \chi_k^2$  son independientes, el cociente:

$$T = \frac{Z}{\sqrt{V/k}} \sim t_k \quad (28)$$

es decir,  $T$  tiene distribución  $t$ -student con  $k$  grados de libertad. Sustituyendo  $Z$  y  $V$  con  $k = n - p$ :

$$\begin{aligned} T &= \frac{Z}{\sqrt{V/(n-p)}} \\ &= \frac{\mathbf{X}'\hat{\beta} - \mathbf{X}'\beta}{\sigma\sqrt{\mathbf{X}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}}} \sqrt{\frac{(n-p)\sigma^2}{(n-p)S^2}} \\ &= \frac{\mathbf{x}'\hat{\beta} - \mathbf{x}'\beta}{\sigma\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}}} \left( \frac{\sigma}{S} \right) \\ &= \frac{\mathbf{x}'\hat{\beta} - \mathbf{x}'\beta}{S\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}}} \end{aligned} \quad (29)$$

Defina el error estándar de  $\hat{\mu}(\mathbf{x})$  como:

$$\text{SE}(\hat{\mu}(\mathbf{x})) = S\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}} \quad (30)$$

por tanto:

$$T = \frac{\mathbf{x}'\hat{\beta} - \mathbf{x}'\beta}{S\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}}} = \frac{\hat{\mu}(\mathbf{x}) - \mu(\mathbf{x})}{\text{SE}(\hat{\mu}(\mathbf{x}))} \sim t_{n-5} \quad (31)$$

## 5.3 Intervalo de Confianza para $\mu(\mathbf{X})$

Esta cantidad  $T$  es nuestra variable pivote, pues su distribución  $t_{n-5}$  es completamente conocida y no depende de los parámetros desconocidos. Para un nivel de confianza  $(1 - \alpha)$ , seleccionamos el percentil  $t_{\alpha/2, n-5}$  tal que:

$$\begin{aligned} P\left(-t_{\alpha/2, n-5} \leq T \leq t_{\alpha/2, n-5}\right) &= 1 - \alpha \\ P\left(-t_{\alpha/2, n-5} \leq \frac{\hat{\mu}(\mathbf{x}) - \mu(\mathbf{x})}{\text{SE}(\hat{\mu}(\mathbf{x}))} \leq t_{\alpha/2, n-5}\right) &= 1 - \alpha \\ P\left(-t_{\alpha/2, n-5} \cdot \text{SE}(\hat{\mu}(\mathbf{x})) \leq \hat{\mu}(\mathbf{x}) - \mu(\mathbf{x}) \leq t_{\alpha/2, n-5} \cdot \text{SE}(\hat{\mu}(\mathbf{x}))\right) &= 1 - \alpha \\ P\left(\hat{\mu}(\mathbf{x}) - t_{\alpha/2, n-5} \cdot \text{SE}(\hat{\mu}(\mathbf{x})) \leq \mu(\mathbf{x}) \leq \hat{\mu}(\mathbf{x}) + t_{\alpha/2, n-5} \cdot \text{SE}(\hat{\mu}(\mathbf{x}))\right) &= 1 - \alpha \end{aligned} \quad (32)$$

Por tanto si  $\mu(\mathbf{x}) = \mathbf{x}'\beta$ ,

$$\begin{aligned} \text{IC}_{(1-\alpha)}(\mu(\mathbf{x})) &= \hat{\mu}(\mathbf{x}) \pm t_{\alpha/2, n-5} \cdot \text{SE}(\hat{\mu}(\mathbf{x})) \\ &= \mathbf{x}'\hat{\beta} \pm t_{\alpha/2, n-5} \cdot S\sqrt{\mathbf{x}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}} \end{aligned} \quad (33)$$

Por tanto, respondiendo al problema inicial: si  $\mu = \mathbb{E}[Q_o \mid Q_{gl}]$  deseamos encontrar,

$$\text{IC}_{(1-\alpha)}(\mu) = \hat{\mu}(Q_{gl}) \pm \delta(Q_{gl}). \quad (34)$$

Entonces,

$$\hat{\mu}(Q_{gl}) = (\mathbf{x}(Q_{gl}))'\hat{\beta} \quad (35)$$

$$\delta(Q_{gl}) = t_{\alpha/2, n-5} \cdot S\sqrt{(\mathbf{x}(Q_{gl}))'(\mathbf{X}'\mathbf{X})^{-1}(\mathbf{x}(Q_{gl}))} \quad (36)$$

## Referencias

- [1] Wikipedia contributors. Gauss–markov theorem — Wikipedia, the free encyclopedia, 2026. [Online; accedido el 9-agosto-2026].

## Anexo A: Método de Mínimos Cuadrados

---

## Anexo B: Propiedades de la Varianza

---